CariAgent 产品需求文档

v0.4｜产品需求、关键技术决策与迭代记录

- 1. 文档概览
- 2. 背景、用户与产品目标
  - 2.1 问题定义
  - 2.2 目标用户与核心场景
  - 2.3 目标与边界
- 3. 当前能力与版本范围
- 4. 产品流程与交互
  - 4.1 用户主流程
  - 4.2 系统处理流程
  - 4.3 网页页面与关键动作
  - 4.4 关键异常处理
- 5. 详细功能需求
- 6. AI 行为、评分与追问规则
  - 6.1 事实与证据归属
  - 6.2 检索规则与实现边界
  - 6.3 证据覆盖度分数
  - 6.4 Human-in-the-loop
- 7. 架构、状态与非功能要求
  - 7.1 状态与模块
  - 7.2 质量与运行要求
- 8. 产品演进与关键技术决策
  - 8.1 明确暂缓的技术方向
- 9. 验收、测试与效果评估
  - 9.1 核心验收场景
  - 9.2 已有验证证据
  - 9.3 后续测量口径
- 10. 发布、已知问题与后续安排
  - 10.1 发布基线
  - 10.2 当前重点问题
  - 10.3 下一轮立项原则
- 附录 A：材料与证据索引
- 附录 B：文档维护规则

1. 文档概览

项目	内容
产品	CariAgent：基于真实经历与目标 JD 的 AI 简历定制助手
文档版本	v0.4；这是文档版本，不代表应用另行发布了 v0.4
更新日期	2026 年 10 月 17 日
编写方式	根据历史 PRD、研发日志、设计说明、当前代码及测试记录回溯整理
当前形态	Streamlit 网页 MVP，保留 CLI；中英文独立启动入口，共享核心流程
状态依据	已实现内容以当前仓库为准；历史决定保留其阶段背景；未验证收益不记为实测成果

本文件用于明确产品目标、交互与业务规则、验收条件，并集中记录关键研发取舍。当前代码核对基于 `english-app` 分支提交 `138ed53`。用户已反馈创建英文线上应用，但未提供可复核网址，线上验收不在本文件中标记为通过。

2. 背景、用户与产品目标

2.1 问题定义

求职者通常需要针对不同岗位反复挑选和改写经历，而一份现有简历并不等于其完整经历。原始材料又常有口语化、重复、细节遗漏等问题。直接让大模型生成简历，可能遗漏相关证据、夸大结果，或把不同经历的事实混用。

CariAgent 将简历定制拆成一条可检查的证据链：

理解岗位 → 找到证据 → 判断覆盖与缺口 → 用户补充 → 组织简历。

2.2 目标用户与核心场景

当前优先面向需要针对具体 JD 定制简历的学生与早期职业求职者。跨方向求职者也是潜在用户，但资深复合型人才的专门适配尚未验证。

典型场景：用户持有多段实习、项目和校园经历，为某个目标岗位筛选最相关事实；系统识别可补充的信息，用户选择回答或跳过，最终得到可继续编辑的简历草稿。

用户及问题依据主要来自作者真实求职流程、自测和少量试用反馈，不等同于完成了规模化用户研究。

2.3 目标与边界

目标	产品要求
针对岗位选择经历	检索依据来自目标 JD，避免只做通用润色
保持事实准确	事实可归属到原始经历或用户补充，不编造结果、不跨经历借证据
支持用户参与	用户可理解缺口、回答或跳过，并自主结束补充
交付可使用草稿	简历正文与优化建议独立展示，下载仅含正文
提供英文使用路径	英文界面、提示词、追问、生成与导出使用一致语言

当前不包含：自动搜索并投递岗位、账号与支付系统、跨会话长期事实库、生产级多租户隔离、OCR/视觉解析、PDF 精排版、岗位录用预测，以及已经完成的 LangGraph 多 Agent 架构。

3. 当前能力与版本范围

模块	当前交付
输入	文本编辑；TXT、Markdown、DOCX、文本型 PDF 内容提取；内置虚拟示例
JD 理解	岗位目标、职责、KSA、基础条件与关键词结构化
证据处理	Section 与单段经历解析、混合检索、来源信息、Experience Atoms

模块	当前交付
匹配	材料质量检查、要求覆盖判断、程序评分、适配解释
用户补充	网页逐题回答、跳过、查看提问原因、直接生成
输出	Markdown 简历正文、独立优化建议、Markdown / DOCX 下载
语言	中文 `ui/app.py`；英文 `ui/app_en.py`，分别运行或部署
研发诊断	API 调用元数据、工作流 trace、可选中间 JSON / Markdown 文件

图片扩展名虽出现在上传控件中，当前代码会提示改为粘贴文字，不能据此宣称支持图片理解。网页默认不把生成结果写入 outputs；会话缓存也不等于长期保存资料。

4. 产品流程与交互

4.1 用户主流程

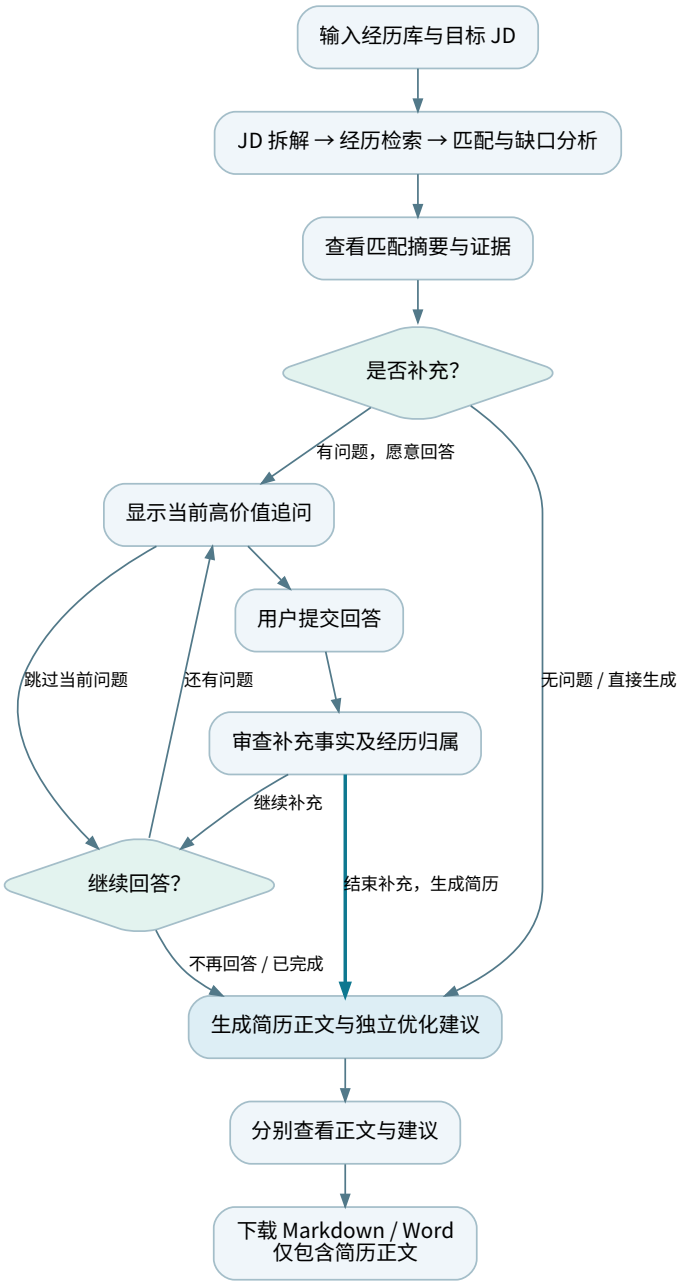


图 1：用户主流程；补充事实审查后可直接生成简历

图中“审查补充事实及经历归属”可以直接进入“生成简历”，也可以继续处理下一题；不要求返回匹配摘要，不强制回答全部问题。

操作边界：用户应先提交当前回答，再点击生成。当前生成按钮不会代为提交尚未提交的文本框内容。

4.2 系统处理流程

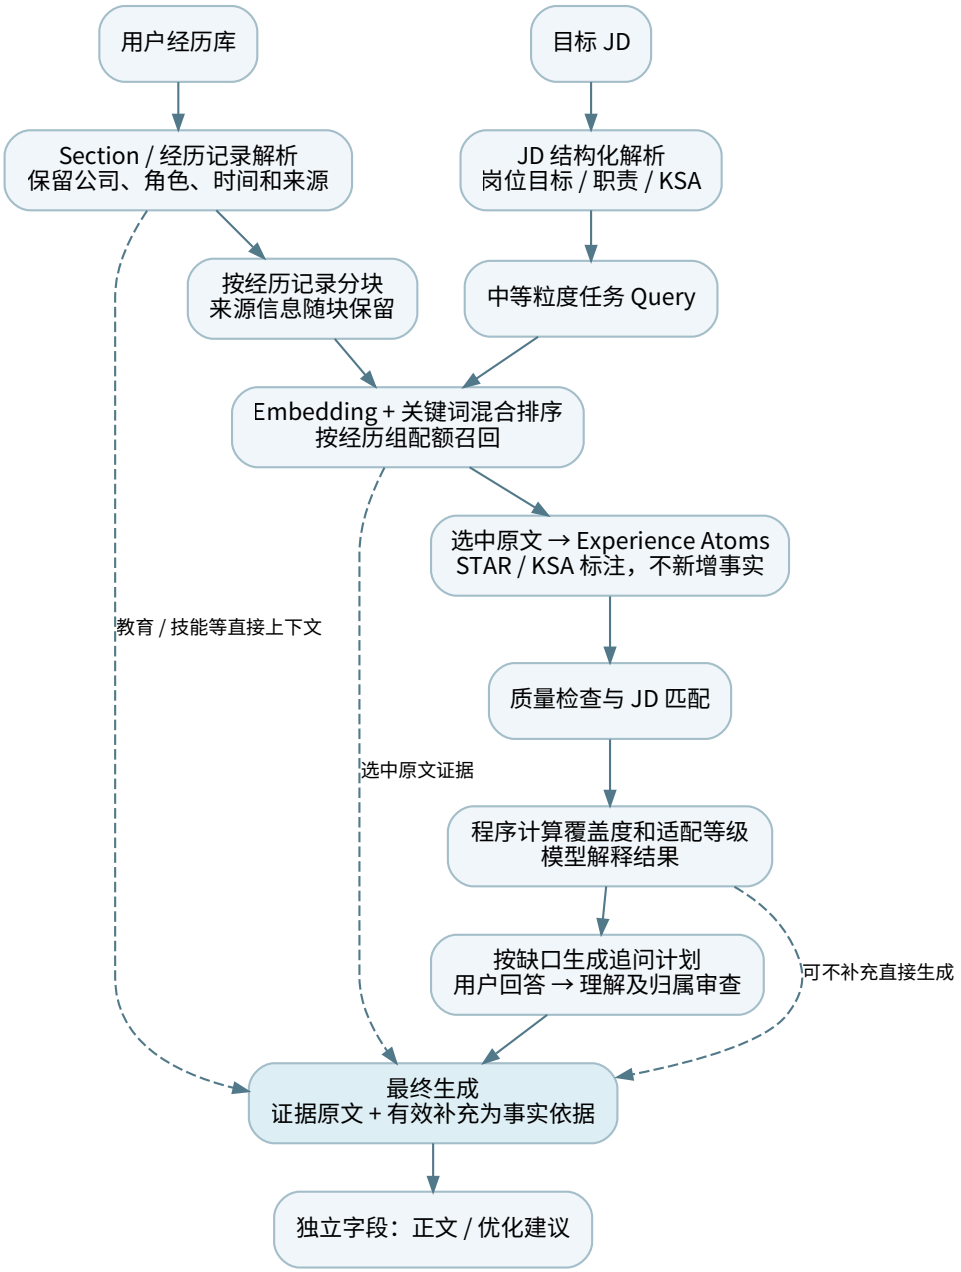


图 2：系统证据处理与生成流程

阶段	输入 → 输出	职责边界
JD 解析	JD → 结构化岗位要求	不把 JD 未写出的细分能力任意扩展为独立要求
经历解析	经历库 → sections / experience records	分类并保留事实；同公司同角色同时间的任务不拆成多份经历
证据检索	经历块＋JD task units → selected chunks	检索原文，保留来源；不直接生成简历
结构化与检查	选中证据 → atoms、材料质量检查	标注 STAR / KSA；不重新读取完整经历库绕过检索
匹配与评分	JD＋atoms → 覆盖、缺口、分数与解释	模型分类，程序计算分数；解释不能扩大结论
追问与理解	缺口＋回答 → 审查后的补充	不替用户补事实，不自动写回原经历库

阶段	输入 → 输出	职责边界
最终生成	原文证据＋有效补充＋必要标注 → 两类输出	正文和建议分离，不暴露内部字段

4.3 网页页面与关键动作

页面	用户操作	结果
经历库	编辑、导入、继续	将经历作为当前流程输入；可查看解析后的经历分类
目标 JD	编辑、导入、分析	展示岗位要求与关键词，再进入匹配
匹配摘要	查看适配解释、强项、缺口和证据	用户决定是否继续补充；低分是建议，不替用户决定停止
AI 追问	查看原因、提交、跳过、返回、直接生成	已提交补充用于本轮；可不回答所有问题
简历草稿	查看正文及独立建议、下载	Markdown 与 Word 文件只包含正文

4.4 关键异常处理

情况	预期行为及当前限制
输入为空	在发起有效分析前提示补充输入
文件不支持或解析失败	显示原因，允许改用纯文本；不伪装成读取成功
缺少 Key、API 调用失败	显示错误，保留页面可用性；当前不承诺任意节点自动恢复
无候选追问	允许直接生成
不知道、没有或跳过	接受信息边界，不推断不存在的结果
材料更新	不应把旧输入的分析当作新结果；现有缓存键包含输入与语言，但编辑同步和旧状态清理仍需专项验收
刷新、离开或服务重启	不承诺跨会话恢复；页面内切换与长期保存不是同一能力

5. 详细功能需求

P0 表示核心路径必需，P1 表示辅助理解或研发效率。验收条件描述应有行为；是否已通过见第 9 章。

编号	优先级	需求与关键规则	验收条件
IN-01	P0	输入完整经历库与一个目标 JD，支持声明的文本文件格式	两项输入可进入分析；空输入和不支持类型有明确反馈
JD-01	P0	用 KSA 理解岗位，基础学历、年限等独立保留	结构化结果反映原 JD；不任意增加细碎要求
EV-01	P0	先解析 section 和单段经历，再在经历组内检索	工作/实习与项目独立召回；每块有可识别来源
EV-02	P0	仅对选中证据结构化，事实与标注分离	atom 关联正确经历；冲突时以原文与用户回答为准
MT-01	P0	给出覆盖判断、缺口及程序计算的适配等级	确定的匹配标签产生确定分数；文字解释不重新定分
HU-01	P0	基于高价值缺口排序追问，解释提问目的	用户能看到当前问题及相关要求 / 经历，并可跳过
HU-02	P0	审查已提交回答，保留事实归属，仅用于本轮	回答与问题关联；不混入另一段经历，不自动更新底层事实库
HU-03	P0	用户可以结束补充并生成简历	审查后有直接生成路径；无需回到匹配摘要或答完所有题
RES-01	P0	输出简历正文与优化建议两个独立字段	页面分区展示；Markdown、DOCX 均只导出正文

编号	优先级	需求与关键规则	验收条件
RES-02	P0	保留真实公司、角色及已知时间；不编造量化成果	输出能回溯证据；缺失内容用稳健表达，不填假数字
EN-01	P0	英文入口覆盖界面、提示词、本地追问、错误回退和输出	英文示例链路无中文残留；不改 schema 键、枚举及事实关联
OBS-01	P1	保留可调试状态和调用元数据	可定位阶段、输入输出及调用量；日志不记录密钥

状态一致性补充：v0.3 记录过编辑草稿与业务输入分离的修复，但当前代码未见同名实现。该问题保留为待核实项，不能仅依据旧文档标记解决。

6. AI 行为、评分与追问规则

6.1 事实与证据归属

事实来源仅包括原始经历、检索原文及用户补充。JD 分析、atoms、匹配标签、分数和摘要是辅助标注，不是新增事实。

- 每条证据随流程保留 section、公司/项目、具体经历及相关问题的关联。
- 同一经历内任务可合并表达，不得把不同经历的行动或成果拼到一起。
- 用户否认或无法确认的信息不写成事实；缺少 Result 不补造结果。
- 正文不出现 chunk ID、内部 score、检索元数据或调试分析。
- 模型输出使用 schema 约束结构；结构正确仍需核对事实和归属。

6.2 检索规则与实现边界

项目	当前方案
Query	岗位目标、主要职责形成中等粒度 task units，关键词 / KSA 辅助
文档粒度	经历原文 chunk；默认长度 620 字符、重叠 100 字符
排序	语义相似度与关键词重合混合；默认权重 0.72 / 0.28
召回组配额	工作/实习 12、项目 6、校园/其他 3；是 chunk 配额，不是简历 bullet 数
直接上下文	教育、技能、证书等不参与同一竞争式召回，保留为背景
Embedding	`text-embedding-3-small`
持久化	运行时 embedding 与内存相似度计算；未部署持久化向量库

上述参数是当前实现基线，不是所有人群通用的最优值。最终生成保留选中原文，默认不截断；优先减少重复中间上下文，再考虑损失原始证据的节省方式。

6.3 证据覆盖度分数

Readiness score 衡量当前材料对 JD 的证据覆盖，不是录用概率或候选人整体能力分。

内部得分 = Σ(要求权重 × 覆盖分) / Σ要求权重；内部范围 0–1，界面可转换为百分制。

覆盖等级	strong	medium	weak	none
覆盖分	1.00	0.65	0.35	0.00

当前重要性映射：high → 1.5；medium → 1.0，若为 ability 则为 0.8；low → 0.6。覆盖等级由模型的 match level 与 evidence quality 保守映射后计算。

百分制区间	适配等级	展示含义
⩾85	high_fit	高覆盖，可继续组织简历
⩾70 且 <85	good_fit	良好覆盖
⩾55 且 <70	partial_fit	部分覆盖，谨慎补充
⩾40 且 <55	weak_fit	有限覆盖

百分制区间	适配等级	展示含义
<40	low_fit	核心要求支撑不足，建议重新考虑

程序计算减少了算分漂移，但模型仍参与前置分类，因此重复运行不保证完全同分。早期日志的多因子乘法、STAR 完整度等属于探索记录，不是当前总分公式。

6.4 Human-in-the-loop

网页当前根据匹配缺口生成候选问题，按优先级逐题展示；用户可提交、跳过或随时生成。回答理解结果保留可用事实与经历关联；页面中的补充后估计分不能当作重新执行完整匹配后的实测提升。

必须区分历史机制与当前入口：

项目	网页当前行为	CLI / 历史机制
初始问题	按缺口生成并排序展示	另有话题池与交互控制
高分停止	页面不按 0.8 阈值强制跳过所有追问	CLI 存在 readiness 阈值判断
同话题深挖	当前网页主要处理既有候选题	CLI 有动态同话题追问、澄清及预算控制（当前常量：总问题上限 10、每话题追加上限 2、澄清预算 1）
用户结束	可直接点击生成	可使用控制词结束

“顺着回答深入追问”是研发中的重要探索，不能据此宣称当前网页已完整采用 CLI 的动态追问机制。

7. 架构、状态与非功能要求

7.1 状态与模块

当前为共享工作流函数与统一状态驱动的多步骤 AI 应用，尚未迁移为 LangGraph 多 Agent 系统。用户体验保持同一助手连续理解，但各模型调用不必继承完整对话。

状态层	保存内容
原始事实	经历库、JD、补充回答
检索证据	sections、选中 chunks、provenance
结构化标注	atoms、质量检查、匹配与缺口
决策与交互	分数、适配结论、问题、审查结果、分支记录
展示与诊断	正文、建议、trace、API payload 元数据

关键模块：`core/simple_mvp.py` 管理步骤与状态；`core/retrieval.py` 负责检索；`prompts/` 与 `prompts/en/` 管理提示词；`ui/app.py` 提供共享页面，`ui/app_en.py` 启动英文模式。

7.2 质量与运行要求

维度	要求与当前边界
正确性	不制造事实、不串经历；依赖样例和人工核查，尚无大规模事实准确率数据
等待体验	展示阶段进度与错误；日志曾记录约 3 分 20 秒的单次等待，不作为稳定性能基线
稳定性	支持调用重试及页面报错；尚无跨重启 checkpoint、完整后台任务恢复或稳定 SLA
隐私	Key 通过运行环境或 Streamlit Secrets 注入；资料与密钥不提交 GitHub；原文会发送至模型 / embedding 服务，隐私告知仍需完善
存储	网页默认 `CARIAGENT_SAVE_OUTPUTS=0`；会话与缓存可能留有运行数据，不承诺跨会话保存，也不等于零留存
成本	记录调用元数据与 usage，按步骤传递必要上下文；没有经控制实验验证的节省比例
语言	中英文分别部署，核心逻辑复用；不通过修改来源归属或虚构名称实现翻译

8. 产品演进与关键技术决策

以下按材料可确认的阶段编排；无明确日期的阶段不补造日期或发布版本号。历史中的“已解决”反映当时结论，不替代当前代码及测试核对。

阶段	问题 / 观察	关键决策及取舍	证据与结果
2026-05-08：场景形成	作者投递时反复评估岗位、筛选所有经历、定制简历	从完整自动求职设想中收束为经历库＋JD 的证据匹配与生成；保留用户判断	研发日志记录原始求职路径及范围考虑；未实现自动投递
早期：追问与可解释评分	全量生成难发现遗漏，单凭“AI 觉得足够”无法解释何时停止	引入 STAR/KSA、显式匹配、重要性权重、缺口与停止条件	日志截图保留多种评分与追问方案；部分公式后来被替换
第三、四次自测：追问深度	明明存在多个缺口却只问一题；回答提及另一段经历时，希望自然接续；等待较长	探索优先级、澄清与同话题深挖，区分“没答清楚”与“有价值继续问”	2026-05-16 日志记录体验改善与仍慢；没有可确认的总体提升比例
RAG 引入：从全量阅读到检索	上下文增大、无关经历稀释注意力、成本与时延压力	将证据选择显式化：chunk、embedding、语义＋关键词混合；为按 JD 按需读取做准备	研发日志与 RAG 日志；减少后续全量传递，但初始 section parsing 仍读取经历库
Query 纠偏：细 KSA → task units	抽象细 query 出现关键词像、事实不对应的误召回	改用岗位目标与职责的中等粒度 query；KSA 继续辅助理解，不直接等于细碎检索单元	RAG 日志记载纠偏，当前代码保留 task units；无严格前后召回率实验
召回结构：Section-aware	项目信息密度高，压过工作/实习证据	各经历组独立检索与配额；教育/技能直接进入上下文	RAG 日志与现行代码；保留职业经历空间，配额仍需对不同人群评估
事实边界：Provenance	曾把一段组织经历的内容写入另一段经历	从 section、经历记录、chunk 到 atom / match / answer 传递来源；避免摘要成为新事实	RAG 日志有错挂靠案例；来源字段是约束机制，不等于已证明零错误
Step 职责收窄与上下文控制	Step 4 隐式继承全量材料，可能绕过检索、token 过大	Step 4 只结构化选中原文；分步独立调用，以必要上下文和统一状态保持连续性	Workflow 说明及代码；最终生成仍优先保留选中原文，不为省 token 默认截断
稳定输出与评分	模型结构不稳定、评分可能漂移	使用 JSON schema；LLM 做分类与解释，程序计算覆盖总分和等级	v0.3、代码；分类不确定性仍存在，完整稳定性指标待复测
Workflow 与网页化	单脚本、CLI 不利于非技术用户，状态传递难追踪	`WorkflowState`＋步骤函数＋Streamlit 五步交互＋会话缓存与诊断	2026-05-28 Git 记录及 v0.3；旧文档中的编辑同步修复与当前实现存在差异
2026-10-17：输出边界与英文版	建议可能混入下载文件；仅翻译 UI 仍会漏出中文	一次结构化调用返回两个字段；共享核心、独立英文入口、全链路语言覆盖	提交 `138ed53`；首轮真实测试发现残留提示词冲突，修正后重测；英文样例链路通过

8.1 明确暂缓的技术方向

方向	暂缓原因 / 再评估条件
持久化向量库	当前单份经历库、内存检索可用；多用户、多文件、重复检索与跨会话长期存储需求成立后再评估
个人经历知识图谱	属于早期构想，当前以原文证据、来源与结构化标注实现核心路径
LangGraph / 多 Agent	先明确状态、步骤和输入输出；需要 checkpoint、复杂分支、节点重试或并行协作时再做选型
长期事实库	价值在于跨 JD 重用与增量更新；当前未解决账号、写回确认及持久化管理
多模态理解	现有文本提取不等于 OCR、视觉或多模态检索；需独立验证

9. 验收、测试与效果评估

9.1 核心验收场景

场景	通过标准
标准完整路径	经历与 JD 能完成解析、检索、匹配、追问与生成
缺少成果	接受缺失，不制造数字或把任务练习写成真实业务成效

场景	通过标准
经历归属	两段经历的行动、成果、追问补充不互相串用
跳过与提前生成	无需补齐全部问题；已提交回答被使用，未提交内容不冒充已审查
正文 / 建议	页面分开，Markdown / DOCX 文件只含正文
英文一致性	英文示例贯穿页面、问题、审查、正文与建议，无中文残留
编辑与导航	更新输入、返回和继续时不丢最新文本，不使用过期结果；需专项确认
错误恢复	API、文件解析失败有可理解反馈；不将局部失败描述为完成

9.2 已有验证证据

记录	已确认结果	不代表什么
当前离线回归	6 项测试通过：输出分离、提示词边界、页面 / 下载，以及英文提示与导航等	不等于所有交互和异常均被覆盖
中文真实样例	内置经历＋数据分析实习 JD 跑通分析与生成；修复建议混入正文后复测通过	没有完成真人追问验收；曾发现部分时间信息丢失
英文真实样例	8 次模型调用及真实检索；3 个候选追问；模拟回答审查、正文与建议生成通过	不是 3 位用户或 3 轮真人测试，也不是大规模效果结论
英文页面与导出	实际结果填充五个页面，英文文案、Markdown 与 Word 输出检查通过；内部服务健康检查通过	不等于线上部署及外部访问验收
既往试用	面试材料中作者自述约 15 人体验、约 3 人持续使用	不是具有统一时间窗和埋点定义的 20% 留存率

9.3 后续测量口径

指标	定义	当前状态
流程完成率	测试期内生成正文的有效会话 / 已提交有效输入的会话	待建立会话及事件口径，暂无基线
等待时间	分别记录首次匹配完成、提交回答完成、最终生成的耗时	有单次观察，无可靠 p50 / p95
事实错误	在人工核对样本中分别统计编造、跨经历错挂及关键事实遗漏	尚无成体系标注集
追问价值	有效新增事实的回答数 / 已提交回答数，并结合用户评价	模拟调用不能替代真实用户结果
采用情况	用户是否导出、是否修改后使用、是否再次为另一 JD 使用	待试用反馈与合规测量

v0.3 提出的同一输入运行 3 次、分数极差不超过 5 个百分点、等级不跨超过一个相邻等级、强项与缺口重合率至少 60%，继续作为候选稳定性验收目标，**尚未据本轮测试验收**。正式测量时需固定模型、提示词和配置，明确重合率的匹配口径。

10. 发布、已知问题与后续安排

10.1 发布基线

- 原中文版本位于 `main`；本轮共享语言能力及输出分离在 `english-app`，提交 `138ed53`，未合入 main。
- 英文应用使用 `ui/app_en.py`，与中文入口分别部署；Key 在对应托管应用中独立配置，不提交仓库。
- 此文档所列测试针对开发环境中的代码。线上发布需确认分支、入口、Key、实际调用、文件下载及真实浏览器体验。
- 出现回归时回退到已验证代码提交，并确认相关提示词同步回退；不只回退页面文件。

10.2 当前重点问题

问题	处理方向
已知日期在生成中变成“时间未详”	检查记录解析、chunk / atom 元数据与最终上下文传递；独立修复并测试
v0.3 编辑同步记录与当前实现不一致	用真实浏览器验证最新文本的提交、导航及旧分析清理

问题	处理方向
网页与 CLI 追问能力不同	以网页实际行为描述产品，迁移动态追问前单独立项
当前无长期资料管理、断点恢复或成熟监控	结合真实使用频率及失败情况确定优先级，不为框架名称扩架构

10.3 下一轮立项原则

先收集能影响完整使用、事实信任和交付质量的反馈，再选定一轮有明确目标的改动。换云平台、引入 Agent 框架或扩大推广均是候选方案，不列为已承诺功能。每轮补充需求编号、验收场景、代码提交与实际效果，即可在本文件持续维护。

附录 A：材料与证据索引

来源	在本文件中的用途
`cari_agent_prd_v_0_1.md`	确认旧版已废弃；正文缺失，不据此还原具体第一版功能
`cari_agent_prd_v_0_2.md`	本地 MVP、RAG、证据边界、范围与当时待办
`CariAgent_PRD_Portfolio_v0_3.pdf`	网页阶段、评分、交互记录、稳定性目标与作品集说明
`CariAgent研发日志.docx`（含截图）	2026-05-08 构想、追问自测、评分探索、RAG 动机及暂缓方向
`cari_agent_rag_development_log.md`	Query 粒度、section、provenance、Step 4 等关键纠偏
`workflow_design_notes.md`	统一状态、分步职责、原文优先、CLI 阈值及上下文取舍
当前仓库、Git 记录与本轮测试产物	核实现行行为、中英文改动、测试结果及尚未覆盖的范围
作者提供的面试记录及本轮对话	试用反馈、英文版目标与当前部署状态的自述；与运行证据分开

编排参考了 Microsoft PowerToys 的公开规格评审流程与 SCOOBE 功能规格：按问题、目标、优先级、行为、测量和原型组织，关联研发验证。未采用任何公开模板中的虚构目标值作为本项目成果。

- PowerToys 规格评审流程
- PowerToys SCOOBE 功能规格

用户推荐的两篇人人都是产品经理文章尚未成功读取，未将其内容列为已核实依据。

附录 B：文档维护规则

需求改动更新第 5 章；重大方案取舍更新第 8 章；实测和发布更新第 9–10 章。保留“观察、决定、实现、验证”的区别，不追写不存在的研发日期、团队评审或效果数字。

流程图源文件为 `assets/user-flow.dot`、`assets/system-flow.dot`，与对应 SVG 一同维护。Markdown 为主维护文件，网页与 PDF 由同一源文件导出，避免多个版本各自修改。